

人工智能导论第三次作业

张立博 2021012487

2023 年 6 月 24 日

1 第一题 贝叶斯网络

1.1

$$\begin{aligned} & P(-e, -s, -m, -b) \\ &= P(-e)P(-s|-e, -m)P(-m)P(-b|-m) \\ &= 0.6 \times 0.9 \times 0.9 \times 0.9 \\ &= 0.4374 \end{aligned}$$

1.2

$$\begin{aligned} & P(+b) \\ &= P(+b|+m)P(+m) + P(+b|-m)P(-m) \\ &= 1.0 \times 0.1 + 0.1 \times 0.9 \\ &= 0.19 \end{aligned}$$

1.3

$$\begin{aligned} & P(+m|+b) \\ &= \frac{P(+b|+m)P(+m)}{P(+b)} \\ &= \frac{1.0 \times 0.1}{0.19} \\ &= 0.5263 \end{aligned}$$

1.4

$$\begin{aligned} & P(+m|+s, +b, +e) \\ &= \frac{P(+m, +s, +b, +e)}{P(+s, +b, +e)} \\ &= \frac{P(+m)P(+s|+e, +m)P(+b|+m)P(+e)}{P(+m, +s, +b, +e) + P(-m, +s, +b, +e)} \\ &= \frac{P(+m)P(+s|+e, +m)P(+b|+m)P(+e)}{P(+m)P(+s|+e, +m)P(+b|+m)P(+e) + P(-m)P(+s|+e, -m)P(+b|-m)P(+e)} \\ &= \frac{0.1 \times 1.0 \times 1.0 \times 0.4}{0.1 \times 1.0 \times 1.0 \times 0.4 + 0.9 \times 0.8 \times 0.1 \times 0.4} \\ &= 0.5814 \end{aligned}$$

1.5

在 s 未知的情况下, m 和 e 是独立的, 因此:

$$\begin{aligned} & P(+e|+m) \\ &= P(+e) \\ &= 0.4 \end{aligned}$$

2 第二题 变量消除法

2.1

$$\tau_2(b, d, e, f, g) = \sum_c P(c|b)P(d|c)P(e|c, d)P(f|c, e)P(g|c, f)$$

剩余因子如下:

$$\tau_1(b), \tau_2(b, d, e, f, g)$$

2.2

$$\tau_3(b, d, f, g) = \sum_e \tau_2(b, d, e, f, g)$$

剩余因子如下：

$$\tau_1(b), \tau_3(b, d, f, g)$$

2.3

$$\tau_4(b, d, f) = \sum_g \tau_2(b, d, f, g)$$

剩余因子如下：

$$\tau_1(b), \tau_4(b, d, f)$$

2.4

$$\begin{aligned} & P(B = b, D = d | F = f) \\ &= \frac{\tau_1(b) \tau_4(b, d, f)}{\sum_b \tau_1(b) (\sum_d \tau_4(b, d, f))} \end{aligned}$$

2.5

变量消除顺序为： A, G, E, C

消除 A 后，剩余因子为：

$$\tau_1(b), P(c|b), P(d|c), P(e|c, d), P(f|c, e), P(g|c, f)$$

产生的新因子 $\tau_1(b)$ 大小为 1

消除 G 后，剩余因子为：

$$\tau_1(b), P(c|b), P(d|c), P(e|c, d), P(f|c, e), \tau_2(c, f)$$

产生的新因子 $\tau_2(c, f)$ 大小为 1

消除 E 后，剩余因子为：

$$\tau_1(b), P(c|b), P(d|c), \tau_2(c, f), \tau_3(c, d, f)$$

产生的新因子 $\tau_3(c, d, f)$ 大小为 2

消除 C 后，剩余因子为：

$$\tau_1(b), \tau_4(b, d, f)$$

产生的新因子 $\tau_4(b, d, f)$ 大小为 2

3 第三题 带方差的高斯线性回归

由已知

$$\begin{aligned}\log p(D_n; w, \sigma) &= \sum_{i=1}^N \log p(y_n | x_n, w, \sigma) \\ &= \sum_{i=1}^N \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_n - w^T x_n)^2}{2\sigma^2}\right) \\ &= -\frac{N}{2} \log 2\pi - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_n - w^T x_n)^2\end{aligned}$$

分别对 w 和 σ 求导, 得到

$$\begin{aligned}\frac{\partial \log p(D_n; w, \sigma)}{\partial w} &= \sum_{i=1}^N \frac{y_n - w^T x_n}{\sigma^2} x_n \\ \frac{\partial \log p(D_n; w, \sigma)}{\partial \sigma} &= \sum_{i=1}^N \frac{1}{\sigma} - \frac{(y_n - w^T x_n)^2}{\sigma^3}\end{aligned}$$

令导数为 0, 得到

$$\begin{aligned}\sum_{i=1}^N \frac{y_n - w^T x_n}{\sigma^2} x_n &= 0 \\ \sum_{i=1}^N \frac{1}{\sigma} - \frac{(y_n - w^T x_n)^2}{\sigma^3} &= 0\end{aligned}$$

解得

$$\begin{aligned}w_{ML} &= (X^T X)^{-1} X^T Y \\ \sigma_{ML}^2 &= \frac{1}{n} (Y - X w_{ML})^T (Y - X w_{ML})\end{aligned}$$

故

$$\begin{aligned}\hat{w} &= (X^T X)^{-1} X^T Y \\ \hat{\sigma} &= \sqrt{\frac{1}{n} (Y - X \hat{w})^T (Y - X \hat{w})}\end{aligned}$$

其中 x_n 为 $d \times 1$ 的向量, y_n 为标量, w 为 $d \times 1$ 的向量。

X 为 $n \times d$ 的矩阵, Y 为 $n \times 1$ 的向量, X 的第 i 行为 x_i^T , Y 的第 i 行为 y_i 。

4 第四题 采样

4.1

$$\alpha_{ij} = \min\{1, \frac{\pi_j Q_{ji}}{\pi_i Q_{ij}}\}$$

下一个状态为 (1, 3) 的概率为

$$\begin{aligned}\alpha_{(2,2),(1,3)} &= \min\{1, \frac{p(1,3)Q}{p(2,2)Q}\} \\ &= \min\{1, \frac{p(1,3)}{p(2,2)}\} \\ &= \min\{1, \frac{1 + \ln(1 \times 3 + 2 \times 1 + 3 \times 3)}{2 + \ln(2 \times 2 + 2 \times 2 + 3 \times 2)}\} \\ &= \min\{1, \frac{1 + \ln(14)}{2 + \ln(14)}\} \\ &= 0.784\end{aligned}$$

下一个状态为 (3, 4) 的概率为

$$\begin{aligned}\alpha_{(2,2),(3,4)} &= \min\{1, \frac{p(3,4)Q}{p(2,2)Q}\} \\ &= \min\{1, \frac{p(3,4)}{p(2,2)}\} \\ &= \min\{1, \frac{3 + \ln(3 \times 4 + 2 \times 3 + 3 \times 4)}{2 + \ln(2 \times 2 + 2 \times 2 + 3 \times 2)}\} \\ &= \min\{1, \frac{3 + \ln(30)}{2 + \ln(14)}\} \\ &= 1\end{aligned}$$

4.2

若初始点位于 (2, 2)，则第一次采样过程需要采样 x_1 ，提议分布 $q(x_1)$ 的形式为

$$\begin{aligned}q(x_1) &= p(x_1|x_2) \\ &= \frac{p(x_1, x_2)}{p(x_2)} \\ &= \frac{x_1 + \ln(x_1 x_2 + 2x_1 + 3x_2)}{\sum_{x_1=1}^{100} (x_1 + \ln(x_1 x_2 + 2x_1 + 3x_2))} \\ &= \frac{x_1 + \ln(x_1 \times 2 + 2x_1 + 3 \times 2)}{\sum_{x_1=1}^{100} (x_1 + \ln(x_1 \times 2 + 2x_1 + 3 \times 2))}\end{aligned}$$

第二次采样过程中需要采样的变量为 x_2 ，若采样到 $x_1 = 42$ ，则提议分布的形式为

$$\begin{aligned} q(x_2) &= p(x_2|x_1) \\ &= \frac{p(x_1, x_2)}{p(x_1)} \\ &= \frac{42 + \ln(42x_2 + 2 \times 42 + 3x_2)}{\sum_{x_2=1}^{100} (42 + \ln(42x_2 + 2 \times 42 + 3x_2))} \end{aligned}$$

5 第五题 Baum-Welch 算法

5.1

由已知:

$$q(Z) = P(Z|X, \theta^{old})$$

所以:

$$\begin{aligned} J(\theta) &:= L(q(Z), \theta) = \sum_Z q(Z) \log \frac{P(X, Z|\theta)}{q(Z)} \\ &= \sum_Z q(Z) \log P(X, Z|\theta) - \sum_Z q(Z) \log q(Z) \\ &= \sum_Z P(Z|X, \theta^{old}) \log P(X, Z|\theta) - \sum_Z P(Z|X, \theta^{old}) \log P(Z|X, \theta^{old}) \end{aligned}$$

又因为:

$$\hat{Z} = \arg \max_Z P(Z|X, \theta^{old}) \propto \arg \max_Z P(X, Z|\theta^{old})$$

所以:

$$\arg \max_{\theta} J(\theta) = \arg \max_{\theta} \sum_Z P(X, Z|\theta^{old}) \log P(X, Z|\theta)$$

5.2

根据 HMM 的定义，可以将 $P(X, Z|\theta)$ 表示为:

$$P(X, Z|\theta) = P(x_1, x_2, \dots, x_T, z_1, z_2, \dots, z_T|\theta)$$

根据 HMM 的独立性假设

$$\begin{aligned}
P(X, Z|\theta) &= P(x_1, x_2, \dots, x_T | z_1, z_2, \dots, z_T, \theta) P(z_1, z_2, \dots, z_T | \theta) \\
&= P(x_1, x_2, \dots, x_T | z_1, z_2, \dots, z_T, \theta) P(z_1 | \theta) P(z_2 | z_1, \theta) \dots P(z_T | z_{T-1}, \theta) \\
&= P(x_1 | z_1, \theta) P(x_2 | z_2, \theta) \dots P(x_T | z_T, \theta) P(z_1 | \theta) P(z_2 | z_1, \theta) \dots P(z_T | z_{T-1}, \theta)
\end{aligned}$$

其中

$$\begin{aligned}
P(x_t | z_t, \theta) &= b_{z_t}(x_t) \\
P(z_t | z_{t-1}, \theta) &= a_{z_{t-1} z_t} \\
P(z_1 | \theta) &= \pi_{z_1}
\end{aligned}$$

所以

$$\begin{aligned}
P(X, Z|\theta) &= \pi(z_1) B(z_1, x_1) A(z_1, z_2) B(z_2, x_2) \dots A(z_{T-1}, z_T) B(z_T, x_T) \\
&= \pi(z_1) \prod_{t=1}^{T-1} A(z_t, z_{t+1}) \prod_{t=1}^T B(z_t, x_t)
\end{aligned}$$

5.3

令 $Q(\theta, \theta^{old}) = \sum_Z P(X, Z|\theta^{old}) \log P(X, Z|\theta)$, 将 (2) 中结果代入得到

$$\begin{aligned}
Q(\theta, \theta^{old}) &= \sum_Z P(X, Z|\theta^{old}) \log P(X, Z|\theta) \\
&= \sum_Z P(X, Z|\theta^{old}) \log \left\{ \pi(z_1) \prod_{t=1}^{T-1} A(z_t, z_{t+1}) \prod_{t=1}^T B(z_t, x_t) \right\} \\
&= \sum_Z P(X, Z|\theta^{old}) \log \pi(z_1) + \sum_Z P(X, Z|\theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1}) + \sum_Z P(X, Z|\theta^{old}) \sum_{t=1}^T \log B(z_t, x_t)
\end{aligned}$$

上式中 Q 被拆分成了三式之和, 其中每一项仅与 θ 中的一个参数有关

5.4

证：

$$\begin{aligned}
 & \sum_Z P(X, Z | \theta^{old}) \log \pi(z_1) \\
 &= \sum_{z_1=1}^N \sum_{z_2, \dots, z_T} P(X, z_1, z_2, \dots, z_T | \theta^{old}) \log \pi(z_1) \\
 &= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \log \pi(z_1) \\
 &= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \log \pi(z_1) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old})
 \end{aligned}$$

由于内部求和符号中的条件概率 $P(z_2, \dots, z_T | X, z_1, \theta^{old})$ 是对给定的 z_1 条件下后续隐藏状态的概率，根据概率的归一性，有：

$$\sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) = 1$$

所以

$$\begin{aligned}
 & \sum_Z P(X, Z | \theta^{old}) \log \pi(z_1) \\
 &= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \log \pi(z_1) \\
 &= \sum_{i=1}^N P(X, z_1 = i | \theta^{old}) \log \pi_i
 \end{aligned}$$

使用拉格朗日乘子法，求 $\sum_Z P(X, Z | \theta^{old}) \log \pi_{z_1}$ 在 $\sum_{i=1}^N \pi_i = 1$ 下取到极大值时 π_i 的值

首先定义拉格朗日函数：

$$L(\pi, \lambda) = \sum_{i=1}^N P(X, z_1 = i | \theta^{old}) \log \pi_i + \lambda (\sum_{i=1}^N \pi_i - 1)$$

题目要求 $\sum_Z P(X, Z | \theta^{old}) \log \pi_{z_1}$ 在 $\sum_{i=1}^N \pi_i = 1$ 下取到极大值，即找到使得拉格朗日函数取到极大值的 π_i 的值

对拉格朗日函数求偏导并令其为 0。

首先对 π_i 求偏导：

$$\frac{\partial L(\pi, \lambda)}{\partial \pi_i} = \frac{P(X, z_1 = i | \theta^{old})}{\pi_i} + \lambda = 0$$

然后对 λ 求偏导：

$$\frac{\partial L(\pi, \lambda)}{\partial \lambda} = \sum_{i=1}^N \pi_i - 1 = 0$$

联立求解得到：

$$\begin{aligned} \pi_i &= -\frac{P(X, z_1 = i | \theta^{old})}{\lambda} \\ \sum_{i=1}^N \pi_i &= -\frac{\sum_{i=1}^N P(X, z_1 = i | \theta^{old})}{\lambda} = 1 \\ \lambda &= -\sum_{i=1}^N P(X, z_1 = i | \theta^{old}) \\ \pi_i &= \frac{P(X, z_1 = i | \theta^{old})}{\sum_{i=1}^N P(X, z_1 = i | \theta^{old})} \end{aligned}$$

5.5

求解 $Q(\theta, \theta^{old})$ 取极大值时 a_{ij} 和 $b_j(k)$ 的取值

求解过程与上一小题类似，首先证明：

$$\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old}) \log a_{ij} \quad (1)$$

证：

$$\begin{aligned}
& \sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1}) \\
&= \sum_{z_1=1}^N \sum_{z_2, \dots, z_T} P(X, z_1, z_2, \dots, z_T | \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1}) \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1}) \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{t=1}^{T-1} \log a_{z_t z_{t+1}} \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} I(z_t = i, z_{t+1} = j) \log a_{ij} \\
&= \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) P(z_2, \dots, z_T | X, z_1, \theta^{old}) I(z_t = i, z_{t+1} = j) \log a_{ij} \\
&= \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old}) \log a_{ij}
\end{aligned}$$

使用拉格朗日乘子法，求 $\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1})$ 在 $\sum_{j=1}^N a_{ij} = 1$ 下取到极大值时 a_{ij} 的值

首先定义拉格朗日函数：

$$L(A, \lambda) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old}) \log a_{ij} + \lambda \left(\sum_{j=1}^N a_{ij} - 1 \right)$$

题目要求 $\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^{T-1} \log A(z_t, z_{t+1})$ 在 $\sum_{j=1}^N a_{ij} = 1$ 下取到极大值，即找到使得拉格朗日函数取到极大值的 a_{ij} 的值

对拉格朗日函数求偏导并令其为 0。

首先对 a_{ij} 求偏导：

$$\frac{\partial L(A, \lambda)}{\partial a_{ij}} = \frac{\sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}{a_{ij}} + \lambda = 0$$

然后对 λ 求偏导：

$$\frac{\partial L(A, \lambda)}{\partial \lambda} = \sum_{j=1}^N a_{ij} - 1 = 0$$

联立求解得到：

$$\begin{aligned}
a_{ij} &= -\frac{\sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}{\lambda} \\
\sum_{j=1}^N a_{ij} &= -\frac{\sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}{\lambda} = 1 \\
\lambda &= -\sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old}) \\
a_{ij} &= \frac{\sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}{\sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}
\end{aligned}$$

接着证明：

$$\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t) = \sum_{j=1}^N \sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old}) \log b_j(k) \quad (2)$$

证：

$$\begin{aligned}
& \sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t) \\
&= \sum_{z_1=1}^N \sum_{z_2, \dots, z_T} P(X, z_1, z_2, \dots, z_T | \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t) \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t) \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{t=1}^T \log b_{z_t}(x_t) \\
&= \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) \sum_{z_2, \dots, z_T} P(z_2, \dots, z_T | X, z_1, \theta^{old}) \sum_{j=1}^N \sum_{k=1}^M \sum_{t=1}^T I(z_t = j, x_t = k) \log b_j(k) \\
&= \sum_{j=1}^N \sum_{k=1}^M \sum_{t=1}^T \sum_{z_1=1}^N P(X, z_1 | \theta^{old}) P(z_2, \dots, z_T | X, z_1, \theta^{old}) I(z_t = j, x_t = k) \log b_j(k) \\
&= \sum_{j=1}^N \sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old}) \log b_j(k)
\end{aligned}$$

使用拉格朗日乘子法，求 $\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t)$ 在 $\sum_{k=1}^M b_j(k) = 1$ 下取到极大值时 $b_j(k)$ 的值

首先定义拉格朗日函数：

$$L(B, \lambda) = \sum_{j=1}^N \sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old}) \log b_j(k) + \lambda \left(\sum_{k=1}^M b_j(k) - 1 \right)$$

题目要求 $\sum_Z P(X, Z | \theta^{old}) \sum_{t=1}^T \log B(z_t, x_t)$ 在 $\sum_{k=1}^M b_j(k) = 1$ 下取到极大值，即找到使得拉格朗日函数取到极大值的 $b_j(k)$ 的值

对拉格朗日函数求偏导并令其为 0。

首先对 $b_j(k)$ 求偏导：

$$\frac{\partial L(B, \lambda)}{\partial b_j(k)} = \frac{\sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})}{b_j(k)} + \lambda = 0$$

然后对 λ 求偏导：

$$\frac{\partial L(B, \lambda)}{\partial \lambda} = \sum_{k=1}^M b_j(k) - 1 = 0$$

联立求解得到：

$$\begin{aligned} b_j(k) &= - \frac{\sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})}{\lambda} \\ \sum_{k=1}^M b_j(k) &= - \frac{\sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})}{\lambda} = 1 \\ \lambda &= - \sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old}) \\ b_j(k) &= \frac{\sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})}{\sum_{k=1}^M \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})} \end{aligned}$$

5.6

由已知

$$\begin{aligned} \gamma_t^{old}(i) &= P(z_t = i | X, \theta^{old}) \\ \xi_t^{old}(i, j) &= P(z_t = i, z_{t+1} = j | X, \theta^{old}) \end{aligned}$$

使用课上讲过的前向-后向算法，对于给定参数 θ^{old} 的 HMM，可以求出：

$$\begin{aligned}\alpha_t^{old}(i) &= P(z_t = i | x_1, x_2, \dots, x_t, \theta^{old}) \\ \beta_t^{old}(i) &= P(x_{t+1}, x_{t+2}, \dots, x_T | z_t = i, \theta^{old})\end{aligned}$$

下面使用 $\alpha_t^{old}(i), \beta_t^{old}(i), a_{ij}^{old}, b_j^{old}(k)$ 表示出 $\gamma_t^{old}(i), \xi_t^{old}(i, j)$
首先表示出 $\gamma_t^{old}(i)$ ：

$$\begin{aligned}\gamma_t^{old}(i) &= P(z_t = i | X, \theta^{old}) \\ &= \frac{P(z_t = i, X | \theta^{old})}{P(X | \theta^{old})} \\ &= \frac{P(z_t = i, x_1, x_2, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\ &= \frac{P(z_t = i, x_1, x_2, \dots, x_t, x_{t+1}, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\ &= \frac{P(z_t = i, x_1, x_2, \dots, x_t | \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = i, \theta^{old})}{P(X | \theta^{old})} \\ &= \frac{P(z_t = i, x_1, x_2, \dots, x_t | \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = i, \theta^{old})}{\sum_{j=1}^N P(z_t = j, x_1, x_2, \dots, x_t | \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = j, \theta^{old})} \\ &= \frac{\alpha_t^{old}(i) \beta_t^{old}(i)}{\sum_{j=1}^N \alpha_t^{old}(j) \beta_t^{old}(j)}\end{aligned}$$

然后表示出 $\xi_t^{old}(i, j)$:

$$\begin{aligned}
\xi_t^{old}(i, j) &= P(z_t = i, z_{t+1} = j | X, \theta^{old}) \\
&= \frac{P(z_t = i, z_{t+1} = j, X | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_t, x_{t+1}, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_t | \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = i, z_{t+1} = j, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, x_1, x_2, \dots, x_t | \theta^{old}) P(z_{t+1} = j | x_1, x_2, \dots, x_t, z_t = i, \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = i, z_{t+1} = j, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, x_1, x_2, \dots, x_t | \theta^{old}) P(z_{t+1} = j | x_1, x_2, \dots, x_t, z_t = i, \theta^{old}) P(x_{t+1}, \dots, x_T | z_{t+1} = j, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, x_1, x_2, \dots, x_t | \theta^{old}) P(z_{t+1} = j | x_1, x_2, \dots, x_t, z_t = i, \theta^{old}) P(x_{t+1}, \dots, x_T | z_{t+1} = j, \theta^{old})}{\sum_{i=1}^N \sum_{j=1}^N P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_t | \theta^{old}) P(x_{t+1}, \dots, x_T | z_t = i, z_{t+1} = j, \theta^{old})} \\
&= \frac{\alpha_t^{old}(i) a_{ij}^{old} b_j^{old}(x_{t+1}) \beta_{t+1}^{old}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t^{old}(i) a_{ij}^{old} b_j^{old}(x_{t+1}) \beta_{t+1}^{old}(j)}
\end{aligned}$$

5.7

回顾 5.4 和 5.5 的结果, 使用 $\gamma_t^{old}(i), \xi_t^{old}(i, j)$ 表示出 $\pi_i, a_{ij}, b_j(k)$

首先表示出 π_i :

$$\begin{aligned}
\pi_i &= \frac{P(z_1 = i | X, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_1 = i, X | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_1 = i, x_1, x_2, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_1 = i, x_1, x_2, \dots, x_T | \theta^{old})}{\sum_{j=1}^N P(z_1 = j, x_1, x_2, \dots, x_T | \theta^{old})} \\
&= \frac{\sum_{t=1}^T P(X, z_1 = i, x_1, x_2, \dots, x_T | \theta^{old})}{\sum_{j=1}^N \sum_{t=1}^T P(X, z_1 = j, x_1, x_2, \dots, x_T | \theta^{old})} \\
&= \frac{\sum_{t=1}^T \gamma_t^{old}(i)}{\sum_{j=1}^N \sum_{t=1}^T \gamma_t^{old}(j)}
\end{aligned}$$

然后表示出 a_{ij} :

$$\begin{aligned}
a_{ij} &= \frac{P(z_t = i, z_{t+1} = j | X, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_T | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_T | \theta^{old})}{\sum_{i=1}^N \sum_{j=1}^N P(z_t = i, z_{t+1} = j, x_1, x_2, \dots, x_T | \theta^{old})} \\
&= \frac{\sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})}{\sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} P(X, z_t = i, z_{t+1} = j | \theta^{old})} \\
&= \frac{\sum_{t=1}^{T-1} \xi_t^{old}(i, j)}{\sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \xi_t^{old}(i, j)}
\end{aligned}$$

最后表示出 $b_j(k)$:

$$\begin{aligned}
b_j(k) &= \frac{P(x_t = k | z_t = j, X, \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(x_t = k, z_t = j, X | \theta^{old})}{P(X | \theta^{old})} \\
&= \frac{P(x_t = k, z_t = j, X | \theta^{old})}{\sum_{j=1}^N P(x_t = k, z_t = j, X | \theta^{old})} \\
&= \frac{\sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})}{\sum_{j=1}^N \sum_{t=1}^T P(X, z_t = j, x_t = k | \theta^{old})} \\
&= \frac{\sum_{t=1}^T \gamma_t^{old}(j) I(x_t = k)}{\sum_{j=1}^N \sum_{t=1}^T \gamma_t^{old}(j)}
\end{aligned}$$

结合上述推理过程, Baum-Welch 算法的伪代码如下:

重复直到收敛:

E 步:

使用前向-后向算法计算 $\alpha_t^{old}(i), \beta_t^{old}(i)$

使用 $\alpha_t^{old}(i), \beta_t^{old}(i), a_{ij}^{old}, b_j^{old}(k)$ 表示出 $\gamma_t^{old}(i), \xi_t^{old}(i, j)$

M 步:

使用 $\gamma_t^{old}(i), \xi_t^{old}(i, j)$ 表示出 $\pi_i, a_{ij}, b_j(k)$

使用 $\pi_i, a_{ij}, b_j(k)$ 更新模型参数 θ

使用更新后的模型参数 θ 计算 $Q(\theta, \theta^{old})$

计算 $Q(\theta, \theta^{old})$ 的相对变化 δ

更新 θ^{old} 为 θ

输出：模型参数 θ

6 第六题 LDA

6.1

Variational EM LDA 的伪代码如下：

```
1      预处理数据集，得到 docs 和 vocab
2      初始化 lda 部分模型参数：K(主题数), V(词汇表大小), alpha(超参数)
3      对给定的文档集合进行模型拟合：
4          初始化监测收敛性的变量 prev_bound(inf), delta(-inf), D(文档数)
5          根据数据初始化模型参数：
6              使用随机选择的文档子集的词频计数初始化每个主题
7              通过最大似然估计计算主题-词分布的对数矩阵 log_betas(V,K)
8              初始化主题-文档分布矩阵 gammas(D,K)
9              # 重复优化参数直到收敛
10             for i in range(max_epochs):
11                 更新参数并计算 bound 的值
12                 计算 bound 的相对变化 delta
13                 打印进度
14                 更新 prev_bound 为当前 bound
15                 检查是否收敛：若是则停止迭代
16                 如果 vocab 不为空且选择展示主题：输出每个主题的高频词
```

6.2

完整代码见附件 `main.py`

6.3

设置不同的 K，得到的结果如下：

0	孩子	情况	网友	时间	工作	介绍	事发	发生
1	医院	公司	警方	发现	孩子	妻子	昨日	医生
2	孩子	调查	发现	现场	工作人员	男子	万元	人员
3	发现	孩子	警方	发生	男子	学生	女士	老人
4	民警	男子	孩子	手机	嫌疑人	警方	报警	派出所

图 1: K=5

0	男子	警方	民警	发现	现场	人员	发生	报警
1	发现	告诉	现场	昨日	找到	相关	医院	万元
2	男子	法院	张某	死亡	医生	发现	情况	案件
3	孩子	妻子	儿子	时间	家人	告诉	医院	离开
4	万元	车辆	发生	发现	公司	法院	赔偿	被告
5	父亲	手机	发生	母亲	生活	孩子	妈妈	事情
6	公司	发现	工作	现场	调查	同学	中国	医院
7	法院	犯罪	被告人	医院	村民	老人	民警	发现
8	民警	孩子	下午	交警	工作	女子	手机	警察
9	孩子	发现	老师	女士	警方	家长	女儿	情况

图 2: K=10

0	孩子	男子	妈妈	医生	网友	公司	女士	法院
1	发生	公司	司机	发现	现场	男子	告诉	事故
2	儿子	医院	李某	发现	告诉	李先生	死亡	人员
3	孩子	民警	男子	两人	法院	陈某	公司	发生
4	男子	现场	民警	司机	公安局	孩子	介绍	情况
5	民警	嫌疑人	男子	工作	警方	医院	案件	发生
6	发现	学生	孩子	情况	学校	广州	调查	男子
7	警方	发现	调查	网友	万元	孩子	事情	情况
8	学生	发现	学校	现场	工作	生活	老师	时间
9	老人	孩子	下午	女士	事发	调查	现场	时许
10	民警	警方	发现	孩子	家中	情况	调查	下午
11	孩子	介绍	提供	男子	公司	标题	人员	女士
12	孩子	老师	学生	学校	处罚	昨日	告诉	家长
13	女子	万元	银行	发现	孩子	告诉	电话	男子
14	发现	老人	民警	医院	报警	女儿	大爷	警方
15	情况	交警	电话	视频	警察	相关	告诉	手机
16	房屋	发生	赔偿	法院	医院	万元	死亡	孩子
17	孩子	警方	男子	介绍	父亲	回家	公司	标题
18	警方	孩子	车辆	报道	现场	男子	公司	标题
19	民警	警方	发现	派出所	调查	医院	介绍	手机

图 3: K=15

6.4

观察结果发现，分类效果最好的是 K=10 的情况，效果比较明显的主题如：

1. 主题 0：男子 警方 民警 发现 现场 人员 发生 报警
2. 主题 5：父亲 手机 发生 母亲 生活 孩子 妈妈 事情

可能的原因如下：

1. K=5 时，每个主题的词汇量较大，负责解释更多的数据变化，这可能导致模型欠拟合，无法捕捉数据中的复杂结构，分类效果较差
2. K=15 时，每个主题的词汇量较小，可能导致模型过拟合，将噪声也作为主题进行建模，影响分类效果，分类效果较差
3. K=10 时，每个主题的词汇量适中，适当地平衡了模型的复杂性和表达能力方面，

分类效果较好